

Challenges in OCR today

Report on experiences from INEL

Niko Partanen 17/3/2017

```
Былыр огонньордоок эмээксин hоготоккоон олорбуттар, биэк огото hyoктар. 1
                                                                                🖪 старину жили одинокие старик со старухой, век-то не имели ребенка.
Биирдэ туран огонньор эппит эмээксинигэр:
                                                                                Однажды старик говорит своей старухе:
paragraph_break
                                                                                paragraph break
                                                                                — Старуха, нам бы хорошо завести своего ребенка.
paragraph_break

    Эмээксин, биһиги оголонуокпутугар бэрт.

sparagraph_break
Онуга эмээксинэ эппит:
                                                                                На это старуха сказала;
/paragraph_break
                                                                                paragraph break

    – Һинилбитигэр оголоммотокпут, кайдак билигин оголонуок-путуй?

    Когда мы были нолодыми, не появился у нас ребенок, как сейчас родим его?

Ол hатаныа дуо? — диэбит.
                                                                                Сможем ли мы?
                                                                                :paragraph_break
paragraph_break
10ну огонньоро эппит:
/paragraph_break
                                                                               Tyr старик сказал:
paragraph_break
— Мин кићи буларыттан атыннык оголоноору гынабын, — диэбит.
                                                                                — Я хочу завести ребенка не так, как у людей бывает.
                                                                                paragraph_break
iparagraph_break
328
Эмээксинэ диэбит:
                                                                                Старуха сказала:
paragraph break
                                                                                paragraph break
— Оголонорго туок кућагана буолуой?!

    Разве худо обзавестись ребенком?!

Оннук буоллагына тэриннэгин дии.
                                                                                Раз так, то ты постарайся.
paragraph break
                                                                                paragraph_break
Маныага огонньоро илими ылбыт, кабыйакаанна туруоралларын курдук кытылга Ş
                                                                                Тогда старик взял сеть, поставил ее как на куропаток, навесив на колья от 🤄
Бу гынан баран: илимининигэр киирэн эккирии-эккирии: "Ohoo-эhээ!" — диэн S
                                                                                Сделав так, вошел внутрь сети и, подпрыгивая на месте, заголосил: "Осоо-эс$
Огурдук үс күн быһыыланар.
                                                                                Вот так три дня делал.
Yhyc күнүгэр таксыбыта, илимигэр уол ого түбэhэн ытыы hытар.
                                                                                На третий день вышел — в сеть мальчик маленький попался, лехит и плачет.
Наны огонньор дьиэтигэр эгэлэр.
                                                                                Старик его домой принес.
iparagraph_break
                                                                                iparagraph break
                                                                                Внес в дом, [посмотрел], а у этого ребенка ни спереди, ни сзади отверстия $
Дьиэгэ кийрбиттэрэ бу оголоро чороокута* да эмэһэтэ дээ бүтэй. З
Уорбут дьон маны дьэ матана курдук каалаан аһаталлар.
                                                                                Обрадованные люди стали кормить его, словно суму [кожаную] набили.
                                                                                Как же будет жить цельный человек, не имеющий отверстия? Тут же и умер.
Бүтэй кићи кайдак буолуой — ћонно өлөн каалбыт.
paragraph_break
                                                                                paragraph_break
Оннук кайа иччититтэн ого кэлэн барбыт диэн былыргылар кэпсииллэр.
                                                                                Вот что рассказывали предки о том, как от духа горы был получен ребенок, и$
paragraph break
                                                                                paragraph_break
330
                                                                                330
```



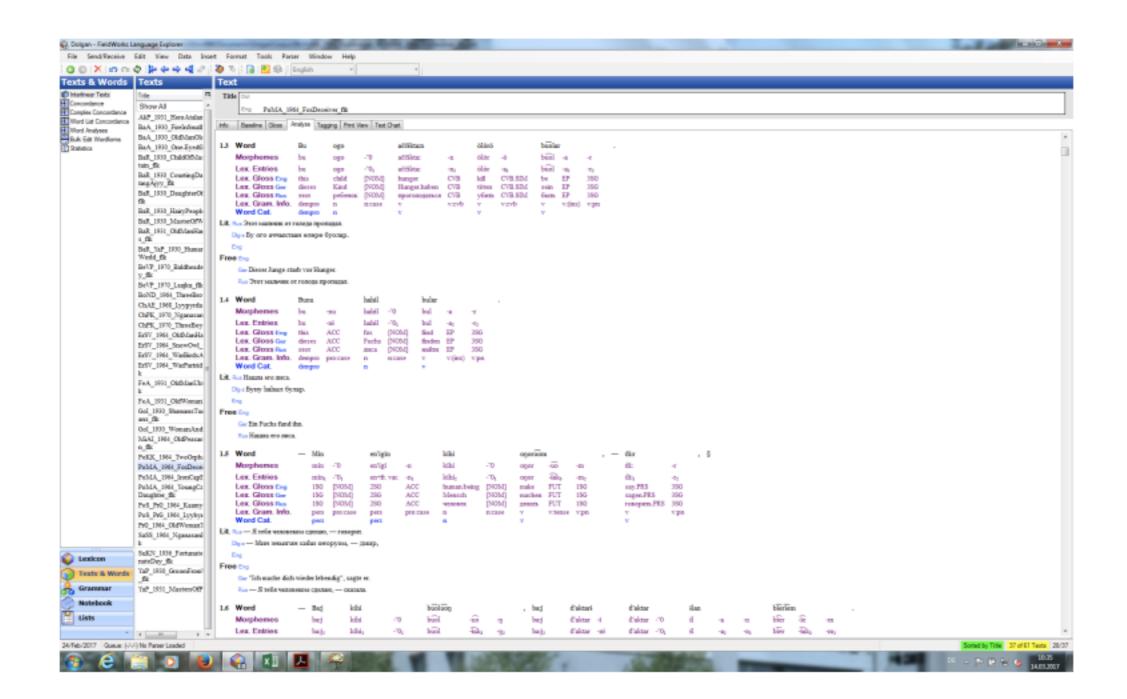
| 1710>> | 1710 >> | 1.8- |
|--------|---------|-----------|
| 1711» | 1711» | 0.245455- |
| 1712» | 1712» | 1.8- |
| 1713» | 1713» | 1.05- |
| 1714» | 1714» | 0.283333- |
| 1715» | 1715» | 1.8- |
| 1716» | 1716» | 3.92754- |
| 1717» | 1717» | 0.20625- |
| 1718» | 1718» | 0.211364- |
| 1719» | 1719» | 0.267391 |
| 1720 | 1720>> | 0.585606- |
| 1721» | 1721» | -0.3 |
| 1722» | 1721» | -0.3 |
| 1723>> | 1721» | 1.8- |
| 1724>> | 1722» | 0.562558- |
| 1725>> | 1723» | 0.221739- |
| 1726>> | 1724» | 1.8- |
| 1727» | 1725» | 3.81136- |
| 1728» | 1726» | 1.8- |
| 1729» | 1727» | 0.259459- |
| 1730» | 1728» | 0.294545 |

hunalign

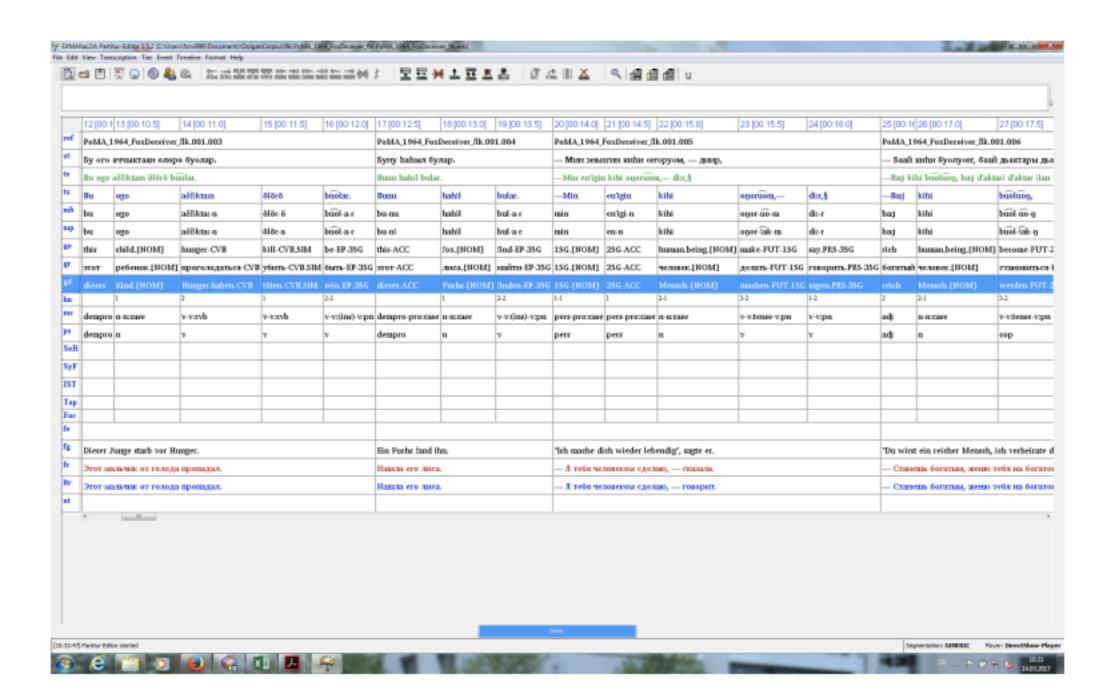


```
\ref title:folklordolgan2000-30 page:328 section:1 par:1 sentence:1
\tx Bɨlɨr ogonn'ordo:k eme:ksin hogotokko:n olorbuttar, biek ogoto huōktar.
\litv Былыр огонньордоок эмээксин hоготоккоон олорбуттар, биэк огото hyoктар.
\litr В старину жили одинокие старик со старухой, век-то не имели ребенка.
\ref title:folklordolgan2000-30 page:328 section:1 par:1 sentence:2
\tx Bi:rde turan ogonn'or eppit eme:ksiniger:
\litv Биирдэ туран огонньор эппит эмээксинигэр:
\litr Однажды старик говорит своей старухе:
\ref title:folklordolgan2000-30 page:328 section:1 par:1 sentence:3
\tx - Eme:ksin, bihigi ogolonu@kputugar bert.
\litv — Эмээксин, биһиги оголонуокпутугар бэрт.
\litr — Старуха, нам бы хорошо завести своего ребенка.
\par
\ref title:folklordolgan2000-30 page:328 section:1 par:2 sentence:4
\tx Onuga eme:ksine eppit:
\litv Онуга эмээксинэ эппит:
\litr На это старуха сказала;
\par
```











| RegE | x (T) | + | Search: | \b(M m)ăn\b | | | |
|------|-------|-------------------------|--------------|--|-------|--|-------|
| # | s | Communication | Speaker | Left Context | Match | Right Context | id[S] |
| 1 | 1 | AA_1914_Mouse_ | flk AA | a pada?, ija!" "Kalla? käštəga?, kola püla: | Măn | kola ej amənzəliem. Let i?gö, kia?dolam." | AA |
| 2 | 1 | AA_1914_Mouse_ | flk AA | "Šuktəlbiba?, šo?!" Kalla? käštəgut, šuktə | Măn | digən igem." Ne kubi, pa kabarbi, di t'uga | AA |
| 3 | 7 | AA_1914_Khan_fl | k AA | aba?bi: "Šində dígən amna?" Inebə öt't'erl | măn | kük no?bə tonəlla?bə ej surarga. To?gən | AA |
| 1 | V | AA_1914_Corpse | flk AA | Nūke amnobi, o?b n'it ibi. N'it ijaandə mă | Măn | nejləm." Ijat mălia: "Naga, man'əkkən ne | AA |
| 5 | ✓ | AA_1914_Corpse | flk AA | nejləm." Ijat mălia: "Naga, man'əkkən ne | Măn | kallam ne pile?." Kalla? t'ürbi, ijabə ba?la | AA |
| 5 | 1 | AA_1914_Corpse_ | flk AA | də. "Ad'am! Aspa? edə?, uja pada?!" "Uj | Măn | tetliem." N'i?də u?bdəbi, t'alaš šūškū ibi | AA |
| 7 | 1 | AA_1914_Corpse_ | flk AA | N'e?le?bliet "I? t'ora?!" "Tăn aspa?lə ko:l | măn | ujam amnu?bi." Ne: "I? t'ora?! Miliem. O | AA |
| 3 | 1 | AA_1914_Corpse | flk AA | ularzaŋgən'ibe?! Ö?le it ularlə!" "Ši? ularza | măn | ularbə amnu?lədən." "İmbijle? amnədən? | AA |
| | 1 | AA_1914_Corpse | flk AA | öt's'ün Güd'ər nünne? ba?bi, u?la sa?məb | Măn | nörbəbiöm šì?n'idə, ularbə amnədən. Šăn | AA |
| 0 | 1 | AA_1914_Corpse | flk AA | ăbəj?le?bddə. Di bazo? šünə tirlölie. "I? t' | Măn | ularəm milem." "Măna ej kere? tăn ularla? | AA |
| 1 | 1 | AA_1914_Corpse | flk AA | ?! Măn ularəm milem." "Măna ej kere? tăn | Măn | imbin'im măna mibi." "No, i? t'ora?! Bar | AA |
| 2 | 1 | AA_1914_Corpse | flk AA | a?də Büz'e amna, šide ko?bdot amna. "A | Măn | nükem ige. Pan tabəndə ularzandə t'abola | AA |
| 3 | 1 | IA_1912_Trickster | flk IA | P'el simabə kajlaba?bi. "Tăn kădə? mola? | Măn | simam t'ezerdələm. Ö?le? mäna, tăn simal | IA |
| 4 | 1 | IA_1912_Trickster | flk IA | əbi. Dizen šobii?. "Kădə? mola? š'a:mna? | Măn | ej š'a:mniam. Măn săgər kuza igem." Ibii? | IA |
| 15 | 1 | IA_1912_Trickster | flk IA | "Kădə? mola? š'a:mna? i?bəl?" "Măn ej š | Măn | săgər kuza igem." Ibii? idəm sogənə sarbii | IA |
| 16 | 1 | NN_1914_Birds_fl | k NN | əššət igel. Nen pi?meendə tülində siktöle? | Măn | toru inen toru kunda tora to?la? kunnim." | NN |
| üke | amn | obi, o?b n'it ibi. N'it | ijaandə măli | a: "Măn nejləm." Ijat mălia: "Naga, man əkkən ne gəndə ma? nuga. Šübi | | | id[S] |





Lament [song]

Speaker: Avdakeya Andzhigatova

Language: Kamas [xas]

Recorded in 1914 by Kai Donner

Published in: A.J. Joki (ed.). 1944. Kat Donners Kamassisches Wörterbuch. Helsinki: Suomalais-Ugrilainen Seura. P. 87.

This publication is part of the <u>INEL project</u>, 2016-Glossed by Gerson Klumpp and Tiina Klooster English translation by Gerson Klumpp

Kijen mille?biem sagər mājazaŋbə i?bəle? kojobi.

gijen mīn-la?bə-bi-m sagər māja-zAŋ-m 1?bə-lA? kojo-bi where go-DUR-PST-1SG black.[NOM.SG] mountain-PL-NOM/GEN/ACC.1SG lie-CVB stay-PST.[3SG]

Where I was going, my black mountains stayed behind

Mille?bəne t'üm kük no?ts'ə? özerle? ba?bi.

min-la2bə-NTA t'ü-m kük no2-t-zi2 özer-lA2 ba2bdə-bi
go DUR-PTCP land NOM/GEN/ACC.1SG green.[NOM.SG] grass NOM/GEN.3SG-INS grow-CVB throw-PST.[3SG]

The land which I walked was grown over with green grass

Sagər mājazaŋbə i?bəle? kojobi, sīri t'ālamzaŋbə ma?la? kojobii?.

sagor māja-zAŋ-m t?bə-lA? kojo-bt sīri d'elam-zAŋ-m
black.[NOM.SQ] mountain-PL-NOM/GEN/ACC.1SQ lie-CVB stay-PST.[3SQ] white.[NOM.SG] Sayan.mountains-PL-NOM/GEN/ACC.1SQ

ma-lA? kojo-bi-jə? stay-CVB stay-PST-3PL

My black mountains stayed behind, my white Sayan mountains were left behind.



Paradox with ABBYY

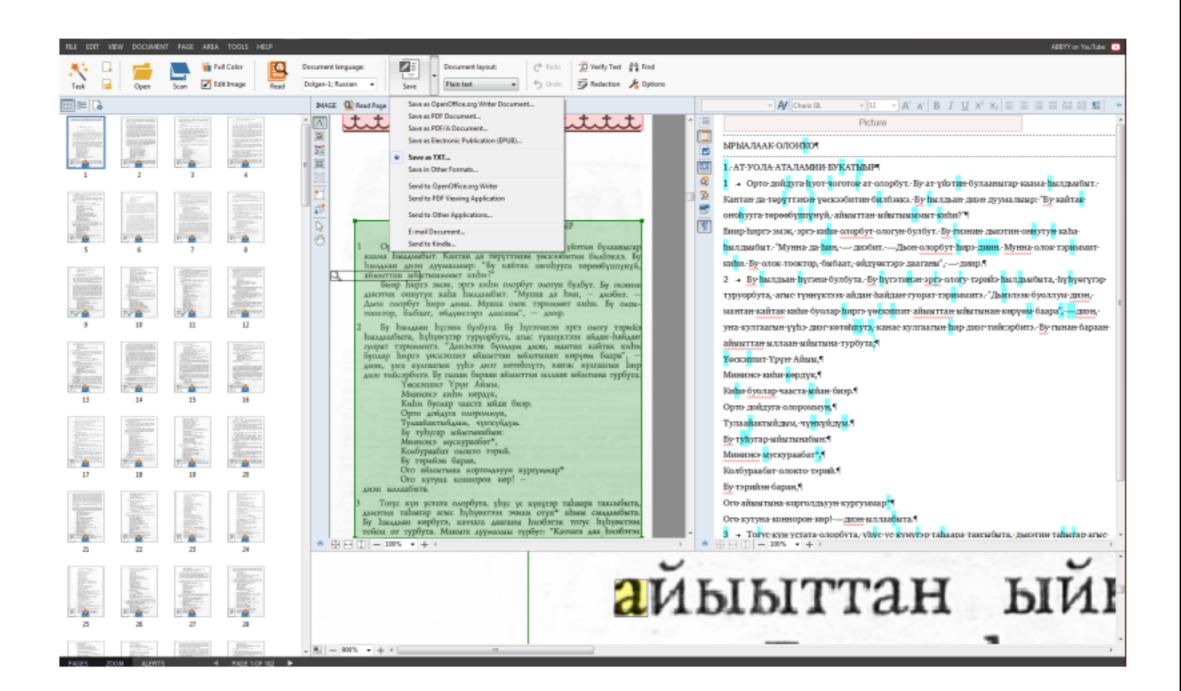
Desktop version

- Good user interface
- Training new models easy, although not transparent
- Practical to do fast post-correction after OCR
- No XML export

Engine version

- Used from command line
- Only pre-defined models
- Cannot be post-corrected in Abbyy Desktop
- Good ALTO XML export







How is this possible?

- In defence of ABBYY, other OCR tools suffer with same
- Maybe it simply is difficult to manage user edits and word/letter position coordinates?

Currently lost information

- Coordinate information on page
- Some formatting
- Footnotes are later added manually as notes
- Time is wasted!



INEL

- Grammars, corpora and language technologies for Indigenous Northern Eurasian Languages (website)
- A long-term project (18 years) funded by Academy of Sciences and Humanities in Hamburg
- The project was applied for by Prof. Dr. Beáta Wagner-Nagy,
 Dr. Michael Riessler and the management of HZSK
- · Research:
 - Institut für Finnougristik / Uralistik at Universität Hamburg (IFUU)
- Infrastructure:
 - Hamburger Zentrum für Sprachkorpora (HZSK)



Why is this a problem? (1/2)

- Reconstructing paragraphs from plain text very unreliable
 - Word coordinate on page gives more cues
- Distinguishing different numberings from one another hard
 - Page numbers, chapter numbers etc.
- Accurate page information nice for citations



Why is this a problem? (2/2)

- No chances to deal with more complex layout in the document
- Hard to make nice ebooks automatically!
 - Ebooks with broken paragraph structure annoying
- Hard to make nice digital facsimiles!
 - Relevant for older and rarer items
- Unnecessary information loss is never desirable!



Future tasks

Combining text and coordinates

- Text files in some collections are nicely corrected
- XML files contain coordinate info
 - It must be possible to do matching between these two files?

Combining corpora for research purposes

Same speakers and writers (Albert Vanejev, Jevgeni Igušev)

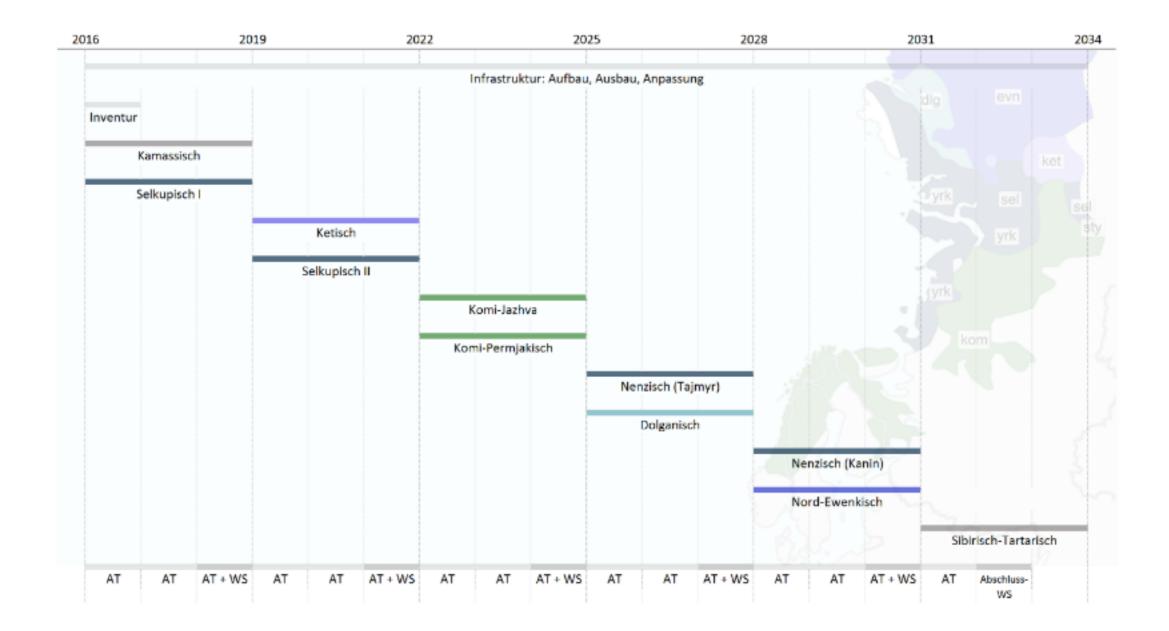


Аттью! Thank you! Спасибо!

CC-BY - Niko Partanen / INEL - 2017

More information and publication here.







Data first phase

- Kamas
 - Kamassisches Wörterbuch (Donner, 1944), glossing complete
 - Audio from last speaker, currently being transcribed
- Selkup
 - A.I. Kuzmina's archive at IFUU: field notes, recordings...
- · Dolgan
 - Texts from existing publications (folklore)
 - Audio recordings from different sources



Pecularities of Dolgan case

- Variety of transcription systems
 - Transliterated to INEL conventions
- Some printed publications rather new
 - High print quality, easy OCR
- Sentence-level translation to Russian
 - Need for aligning
 - Russian translations often in internet already



Basics of INEL OCR workflow

Tools used

- We have been using ABBYY Finereader
- First goal is to bring texts into FLEx with metadata
 - Toolbox file as interchange format
- Audio is aligned later in EXMARaLDA
- Git is used as version control across work phases
 - Most relevant in EXMARaLDA stage
- Hunalign has been practical in alignment checking



Overview to the current workflow



